

具身智能模型技术进展与关系综述

章节导航

- 1. 研究范围与核心判断
- 2. 统一拆解框架与关键技术
- 3. 操作策略与 VLA：从动作模仿到可迁移的机器人基础模型
- 4. 表征、层级推理与世界模型：从理解场景到预测行动后果
- 5. 全身控制与导航：把模型输出变成可持续执行的动作
- 6. 补充模型拆解：数据、反馈与执行共同决定能力
- 7. 数据与评测：如何判断模型真的进步
- 8. 模型关系的综合论述
- 9. 工程架构与开放程度
- 10. 五个未来技术挑战
- 11. 阅读与复现路线

1. 研究范围与核心判断


具身智能模型的进展，可以理解为把互联网中获得的语义知识、真实交互中获得的动作经验，以及仿真中获得的动力学经验接到同一条感知 - 行动反馈链上。仅用“参数量更大”或“机器人外形更像人”解释进步，会遗漏数据分布、动作接口、执行时延与底层控制这些决定性因素。本综述重点研究机器人操作、移动导航和全身控制，并以自动驾驶世界模型作为相邻技术参照；不试图覆盖所有自动驾驶感知、SLAM或传统控制文献。

资料核验截至 2026-09-11。研究采用按技术路线组织的范围综述：追踪奠基工作、原论文、作者项目、官方代码和产品说明，补充2026年的版本更新。它不是具有完整数据库召回率的穷尽性系统综述，也没有进行机器人实验复现；“完整”指在明确范围内覆盖模型机制、关系、数据、评测、工程、产品与未解决问题。论文结果、厂商自报和本文分析会分别标明，未披露的结构或训练数据不作推测。

本文形成五个判断。第一，具身智能不是单一VLA模型的同义词：表征、规划、动作生成、环境预测和伺服控制是可以组合的不同角色。第二，动作生成正在从单步离散预测走向动作块、扩散与流匹配，同时以异步执行缓解推理延迟；这些是可组合的设计维度，不能画成唯一替代链。第三，世界模型的价值要通过行动后果、规划收益或数据收益证明，画面逼真本身不足以证明机器人能力。第四，跨本体数据、领域后训练和反馈学习正在连接预训练与实际部署；标准化文件格式并没有消除动力学差异。第五，长期可靠性、接触反馈与公平评测仍是从演示迈向部署的主要缺口。这些判断由后续各模型与实验条件共同支持。

2. 统一拆解框架与关键技术

先确定模型在闭环中的位置



Closed-loop model roles

设观测为 o_t ，包含图像、深度、本体状态及可用的力/触觉；任务为 g ，历史为 h_t ，本体描述为 e 。策略可写为 $\pi(a_{t:t+H} | o_t, h_t, g, e)$ 。世界模型则预测 $p(z_{t+1} | z_t, a_t, e)$ ，高层规划器选择子目标或技能，低层控制器把期望位姿、速度或关节目标变为实际执行。这里的分解是本文使用的分析框架，并不假定所有研究都有独立命名的模块。

模型角色	输入与输出	代表线索	验证关键
视觉/多模态表征	图像、视频→任务特征	R3M、VC-1、V-JEPA	固定下游头与数据后是否提升
语义与层级规划	指令、状态→子目标/技能/约束	SayCan、PaLM-E、VoxPoser、Gemini ER	计划可执行、失败可发现、可重规划
动作策略与VLA	观测、任务→动作或动作块	ACT、DP、RT、OpenVLA、 π 、GR00T	闭环成功、实时性、适配成本
世界模型	状态、行动→可能的未来	Dreamer、UniSim、JEPA-AC、Cosmos	行动条件有效、后果可信、规划有收益
全身与伺服控制	本体状态、目标→高频关节控制	AMP、PHC、HumanPlus、SONIC、Helix S0	平衡、接触、扰动恢复、硬件约束

这种分层解释了模型之间的许多“看似竞争”：一个强视觉编码器可以服务多个动作头，一个VLA可以调用低层全身策略，一个世界模型可以为已有策略生成训练数据。相反，把语言生成器直接当控制器，或把视频预测器直接当部署机器人策略，会混淆输入输出和验证责任。

每个模型都应回答的八个问题

模型拆解依次回答：要解决什么瓶颈；看见什么输入；模块如何连接；输出什么动作表示；用什么数据和目标训练；推理时如何执行和反馈；贡献来自哪个设计；在哪些条件下仍会失败。网络参数量仅是附加信息。对没有公开网络与训练流程的商业系统，只拆解已披露的接口和系统分工，并标明未知项。

例如同为“VLM + 动作专家”，仍需追问：VLM是否冻结，专家使用特征还是逐层KV，训练是自回归、扩散还是流匹配，状态是否归一化，预测关节绝对值还是末端增量，一次预测多久，实际执行多久，是否用最新观测重规划。这些选择决定了微调数据、吞吐与响应性，不能用同一个架构标签替代。

动作表示：决定迁移与控制成本的接口

离散动作token把连续值量化后转为分类目标，容易接入自回归语言模型，但序列长度、量化精度与推理开销耦合。连续回归直接拟合动作；若同一观测有多种可行策略，简单均值回归可能给出两条路径之间的不可行动作。条件生成方法通过潜变量或去噪建模多峰分布。动作块把时间维一起输出，改善轨迹连贯性，却要求明确观测频率与执行反馈之间的关系。

末端位姿适合跨机械臂共享任务几何，但依赖逆运动学与可达性；关节空间更接近本体执行，却容易与具体关节顺序、零点和自由度绑定。力矩输出将动力学负担更直接地交给策略。三维体素、点云和多视图表示提供空间归纳偏置；触觉与力信息补充被视觉遮挡的接触状态。没有一种表示在所有本体与任务中同时占优，应按精度、数据覆盖和控制接口选择。

学习目标与彼此关系

行为克隆最大化演示动作的条件概率，擅长把示范映射为初始技能，但会受到分布偏移与失败样本不足影响。ACT式条件潜变量模型与动作分块改善长序列拟合；Diffusion Policy通过学习去噪动作序列表达多种有效动作；流匹配学习噪声分布到动作分布之间的连续速度场，通常以数值积分采样。扩散和流匹配都属于条件生成，使用它们并不自动意味着模型预测物理世界。

世界模型学习状态演变，可以在潜空间或视频空间预测；模型式强化学习再利用想象轨迹优化策略，模型预测控制则在部署时搜索候选动作。二者都使用未来，却发生在不同阶段。强化学习或基于经验的后训练以回报和纠错信号改进策略，能与行为克隆初始化结合。把“预训练→行为克隆→RL”写成所有模型必须遵循的固定顺序同样不准确。

高频控制与异步执行不能只看模型吞吐

预测H步不意味着等待H步后才看下一帧；可以只执行前K步再规划，也可以边执行已有动作边预测下一块。异步机制需要时间戳对齐、已经承诺动作的前缀约束、过期动作丢弃和突发扰动的中止逻辑。若端到端延迟为L秒、控制周期为dt，则仅覆盖推理等待就至少需要约 $\text{ceil}(L/dt)$ 个缓冲动作；队列过长又会使控制依赖陈旧观测。这是系统设计约束，不是某篇论文的性能结论。

后续小米Robotics-0的训练前缀与执行对齐、V-JEPA的规划预算，以及Helix/SONIC的分层控制提供了具体例子。评估时应同时记录模型推理时延、相机到动作的观测年龄、抖动、控制频率与任务成功，不能把每秒生成的动作数量当成机器人闭环响应速度。

3. 操作策略与 VLA：从动作模仿到可迁移的机器人基础模型

VLA 的关键并非把语言模型接在机械臂前面，而是让语义、视觉、机器人状态与动作分布在一个可训练的接口中对齐。理解这一主线需要同时观察三条轴：知识从哪里来，动作如何表示和生成，预测如何进入真实时间的控制闭环。网络规模、是否使用扩散和是否采用双系统架构，只分别回答其中一部分问题。

行为克隆把示范中的观测 - 动作映射作为监督目标，仍是许多机器人基础模型的底层训练方式。扩散、flow matching、动作 token 和连续回归首先是不同的策略表示及学习目标，不能据此认定模型已经通过强化学习自主探索。与之不同，RECAP 明确引入回报、价值估计和自主运行数据，改进的是训练信号来源。^{[1][3][25]}

动作表示如何决定模型设计

路线	预测对象与学习目标	代表工作	关键收益	必须检查的代价
单步离散控制	动作分箱，分类或 token 预测	RT-1、RT-2、原始 OpenVLA	便于 Transformer/VLM 训练	分辨率、序列长度、逐 token 推理延迟
连续动作块回归	多步动作与 L1/L2 等监督	OpenVLA-OFT	并行输出、实现直接	多峰动作的条件中位数/均值行为、语言依从性
连续生成策略	从噪声迭代生成动作块	Diffusion Policy、 π_0 、GR00T、SmolVLA	连续精度、多峰分布、动作块一致性	采样次数、端到端延迟、观测过期
压缩动作 token	动作块经 DCT、量化与 BPE	FAST、 π_0 -FAST	降低高频轨迹冗余	压缩误差；训练提速不等于闭环提速
潜动作	从视频变化学习抽象动作，再映射到机器人	OpenDriveLab UniVLA	利用没有机器人动作标签的视频	抽象空间是否保留接触、可达性与控制细节

这些路线可以组合。 π_0 的训练同时使用离散动作目标与连续动作专家；Octo 把机器人预训练与扩散头组合；GR00T 使用名为 DiT 的模块，却以 action flow matching 为核心目标。不能仅凭模块名称把它们都归为同一种扩散训练算法。^{[6][8][15][19][21][31][47]}

典型模型拆解：模仿学习与早期基础模型

ACT (2023)。问题是小误差沿长任务累积，以及低成本双臂示范中的动作差异。输入多视角图像和关节状态，Transformer 条件 VAE 一次预测一段关节位置；训练用动作重建与潜变量正则，推理时以零潜变量并结合重叠预测连续控制。它证明动作分块能提高精细模仿效率，但原始 ACT 不含通用语言知识，也不自动学会超出示范分布的力控策略。^{[1][2]}

Diffusion Policy (2023)。面向同一场景中存在多种合理动作的多峰分布，把连续动作序列看成条件去噪的结果。视觉/状态编码为扩散网络提供条件；训练学习去噪，执行时采样动作块、只运行前缀、重新观测。它提供了后续生成式策略的重要基础；迭代采样有计算代价，原始视觉策略也不能直接等同于经过互联网预训练的 VLA。^{[3][4]}

RT-1 (2022)。针对多任务机器人数据的规模化学习，采用 EfficientNet、语言 FiLM、TokenLearner 和 Transformer，将短图像历史及指令映射为离散控制。原始数据超过 13 万回合、700 个任务，策略约 3 Hz 闭环运行，输出含机械臂、底盘和终止模式。贡献是证明多样机器人数据可被统一策略吸收；局限是机器人与任务覆盖仍集中，语言条件不等于通用推理。^{[5][6]}

RT-2 (2023)。问题从“扩大机器人数据”转向“把互联网语义知识转入控制”。PaLI-X 或 PaLM-E 同时学习机器人轨迹和视觉语言任务，动作被分箱后写成文本 token，推理再还原为控制命令。它能用新语义选物或理解指令，但语义泛化不等于凭空获得新运动技能，且大模型自回归解码增加实时控制压力。它是 RT-1 的研究后继，并非继续训练 RT-1 权重。^{[7][8]}

RT-X / Open X-Embodiment (2023)。这首先是跨机器人数据与模型实验体系，包含 RT-1-X、RT-2-X，不当作为一个唯一网络。初始论文汇集 22 种机器人，通过标准化数据接口训练相应策略，验证多机器人经验可产生正迁移。部署仍需还原目标机器人的动作语义、坐标、单位和频率；统一文件格式没有消除动力学差异。^{[9][10]}

Octo (2024)。它以 80 万条 OXE 轨迹预训练 Transformer 扩散策略，允许语言或目标图像指定任务，并通过模块化输入/动作头适配不同传感器与动作空间。推理生成连续动作块、执行部分后重新规划。其位置是可迁移机器人策略初始化，而非依靠大语言解码器获得所有能力；新平台仍需接口适配及微调。^{[11][12]}

OpenVLA (2024) 与 OpenVLA-OFT (2025) 。原始 OpenVLA 将 DINOv2/SigLIP 视觉特征和 Llama 2 结合，使用约 97 万条机器人示范学习离散动作 token，形成公开的 7B VLA 参考。OFT 明确在这一基础上改造微调方式：并行解码、动作分块、连续表示和 L1 回归。OFT 的价值是揭示输出接口与训练配方对速度和成功率的影响；但 L1 倾向条件中位数，多峰行为、语言依从性仍需专门检验，不能从一个基准结果推出回归普遍优于扩散。[\[13\]\[14\]\[15\]\[16\]](#)

π 系列：连续动作、层级语义、经验学习与记忆

$\pi 0$ (2024) 。输入多视角图像、任务文本、机器人状态和带噪动作，使用 PaliGemma 3B 加约 300M 参数动作专家。flow matching 学习把噪声变成连续动作块，原论文使用 50 步动作块，并可缓存观测前缀来减少重复计算。它先从自有与公开机器人数据学习通用能力，再用高质量数据强化具体精细任务；基础模型表现与专门后训练结果必须区分。[\[17\]\[18\]](#)

FAST / $\pi 0$ -FAST (2025) 。FAST 是动作表示方法：先对动作块做 DCT，再量化并用 BPE 压缩，使高频平滑轨迹变成较短的离散序列。 $\pi 0$ -FAST 是使用这一表示的自回归模型，不能把 FAST 本身列成新的具身机器人架构。它改善训练效率和高频动作 token 的利用率；部署仍有自回归延迟，压缩率不是闭环速度的替代指标。[\[19\]\[20\]](#)

$\pi 0.5$ 与知识隔离 (2025) 。模型沿用 $\pi 0$ 的 VLM - 动作专家结构，并把任务分解为高层语言子任务及低层连续动作，同时使用多机器人和非机器人语义数据。知识隔离阻断动作专家梯度进入 VLM，但仍用离散动作、语言及视觉语言目标训练 VLM，因此并非简单冻结主干。它将语义保持与快速控制结合；公开 openpi 对 $\pi 0.5$ 仅支持 flow head，不能直接认为开源实现覆盖论文全部训练头。[\[21\]\[22\]\[20\]](#)

** $\pi 0.6$ (2025) 与 $\pi^* 0.6$ / RECAP (2025) 。** $\pi 0.6$ 模型卡明确将主干改为 Gemma 3 4B、动作专家约 860M，并保留 $\pi 0.5$ 的层级设计。RECAP 是进一步的训练方法：先离线强化学习，再使用示范、人工接管纠错和自主运行的回报数据；价值函数估计优势，策略在执行时以高优势为条件。应区分“更强监督基础模型”和“从实际经验后训练的策略”；后者的吞吐率提升仍依赖具体任务、回报和干预机制。[\[23\]\[24\]\[25\]](#)

MEM / $\pi 0.6$ -MEM (2026) 。针对遮挡、长流程和重复错误，将压缩的短期视频历史与长期语言记忆结合，再向 VLA 提供历史状态。机器人因此可以依据上次尝试调整策略，或跟踪长任务已完成的步骤。这里验证的是任务内记忆和上下文适应，不能外推成跨用户、终身持久记忆；摘要错误和历史信息丢失仍是独立风险。[\[28\]](#)

$\pi 0.7$ (2026) 。其论文明确继承 $\pi 0.6$ 架构和 MEM，重点变化是训练条件：除了任务/子任务，还加入速度、质量、控制模式与视觉子目标，从而整合机器人、人类和次优自主经验。部署可由高层语义策略生成子任务，并由基于 BAGEL 的轻量世界模型提供视觉目标；连续动作专家执行。它展示技能组合和对强化学习专家经验的吸收，但部分新任务使用逐步语言 coaching 或高层策略适配，不能全部写成单条提示下的全自主零样本能力。[\[26\]\[27\]](#)

截至本次核验，官方 openpi README 列出的公开模型是 $\pi 0$ 、 $\pi 0$ -FAST、 $\pi 0.5$ 。 $\pi 0.6/\pi 0.7$ 的论文与展示存在，不代表这些最新训练权重和全部数据已开放。[\[20\]](#)

GR00T 与紧凑 VLA：规模、跨本体接口和运行工程

SmolVLA (2025) 。面向较低算力 and 社区机器人，采用截短的 SmolVLM2 与约 100M 动作专家，总规模约 450M。视觉、指令及投影后的机器人状态进入模型，冻结 VLM、训练 flow matching 动作块；数据来自 LeRobot 社区与目标任务。紧凑网络及异步执行降低使用门槛，但论文中的同步、逐步反馈与异步实验是不同协议，不能混成统一频率或统一成功率。[\[29\]\[30\]](#)

GR00T N1 (2025) 。图像和语言经 Eagle VLM 编码，DiT 通过 cross-attention 读取语义特征，结合本体专用状态/动作 MLP 生成连续动作块。训练使用 flow matching，混合真实机器人、仿真、生成轨迹和从人类视频提取的潜动作。它与 $\pi 0$ 同属“语义主干加生成动作”方向，但连接方式和训练数据不同，不存在据此认定的权重继承；“System 2”命名也不等于必须显式输出规划文本。[\[31\]](#)

N1.5 (2025)。在 N1 上改进 Eagle 视觉语言主干并冻结其训练，加入 FLARE 未来特征对齐目标，让动作学习获得预测性表示，并扩大 DreamGen 等数据。未来特征对齐不等于完整生成未来像素。官方也明确：通过生成轨迹加入的新动词仍在训练数据中，不能称为完全未训练过的动作泛化。^[32]

N1.6 (2025)。版本技术页指定内部 Cosmos-2B VLM 变体、扩大到 32 层的 DiT、解冻高层 VLM，并对多数本体采用状态相对动作；数据增加 YAM、AgiBot、BEHAVIOR 与 Unitree G1。它同时强调相对动作在小数据下的误差累积、微调过拟合、语言与 OOD 泛化问题，说明动作空间和数据归一化仍是核心工程因素。^[33]

N1.7 (2026)。官方工程页描述 Cosmos-Reason2-2B/Qwen3-VL 主干、约 3B 检查点，训练混合约 3.2 万小时真实/人类数据与 0.8 万小时仿真，并提供 ONNX/TensorRT 导出。核验时官方仓库标记 GA；License 节明确区分代码采用 Apache 2.0、模型权重采用 NVIDIA Open Model License。README 其他位置笼统称“Apache 2.0 商用可许可”，不应据此将代码许可扩展为权重许可；旧 FAQ 的 early access 文案也需按版本核对。商用可用性的发布声明不等于已证明任意现场的可靠率。^{[34][35]}

版本口径存在一处需保留的差异：N1.6 技术页将主干称为内部 Cosmos-2B 变体，而后来的 N1.7 工程博客把前代概括成 Eagle。本文按 N1.6 专属技术页描述，不把含混宣传用语写成精确架构事实。^{[33][34]}

Gemini Robotics：动作模型与具身推理模型的两条支线

Gemini Robotics / ER (2025)。VLA 将图像、语言及机器人状态映射为运动命令；ER 是处理空间理解、任务推理和工具调用的 VLM。两者可组成高低层系统，但 ER 本身不等于能够输出机器人扭矩的控制器。公开报告展示基于 Gemini 的机器人能力，完整训练语料与 VLA 权重仍受限，因此不能补写未披露的动作损失或参数规模。^{[36][37]}

Gemini Robotics 1.5 / ER 1.5 (2025)。VLA 加入 Motion Transfer 与语言思考 - 动作交织，ER 负责工具使用、计划和任务进展判断；训练覆盖 ALOHA、双臂 Franka、Apollo 以及网络多模态数据。它的重要性是跨本体技能转移与任务级 agent 编排，但论文部分长任务结果对 Franka 增加了后训练；公开“无需本体专门后训练”的结果不能覆盖所有实验。^{[38][39]}

ER 1.6 (2026)。模型卡指定 Gemini 3.0 Flash 基础，面向指点、空间关系、仪表读数和多视角成功检测；输出仍是文本/空间表示与工具调用。它是推理支线升级，不是新的运动解码器。官方明确单视角和多视角成功检测使用不同样本，仪表实验也有 agentic vision 配置差别，因此这些柱状图不能简单作同条件排名。^{[40][41]}

Robotics 2、ER 2 与 On-Device 2 (2026)。2026 年 7 月 30 日的官方发布将三者区分：Robotics 2 负责全身与灵巧动作，ER 2 负责理解、计划及多机器人协调，On-Device 2 负责本地运行和新本体适配。ER 2 模型卡指向 Gemini 3.5 Flash；On-Device 2 模型卡则明确继承 Robotics 1.5 技术与端侧 Gemma，并非简单把完整云端模型搬到设备。^{[42][43][44]}

Robotics 2 的公开实验仍显示多指任务和速度存在明显不足。发布时 ER 可通过 AI Studio 使用，完整 VLA 和 On-Device 面向 early-access 合作伙伴；“本地运行”“可通过 API 访问”“公开模型权重”是三个不同概念。缺失的训练目标、参数细节和完整数据清单应保持为未披露。^{[42][44]}

其他代表方向与同名模型辨析

RDT-1B (2024)。以 1.2B diffusion transformer 建模双臂多峰动作，将图像、语言、机器人状态与控制频率结合；通过保留物理含义的统一动作空间汇合多机器人数据，再用双臂示范微调。价值在于把动作的物理语义纳入迁移接口，而不只是补零到同一维数；跨机器人单位、掩码和坐标定义仍需严格处理。^{[45][46]}

OpenDriveLab UniVLA (2025)。从视频帧对和指令出发，在 DINO 特征空间通过 VQ-VAE 学习任务相关潜动作；随后训练 VLA 预测潜动作，再用目标机器人数据训练轻量解码器。这样可以利用没有机器人物理动作标签的人类视频，但潜动作仍需落地到本体控制，抽象表征可能遗漏精细接触与动力学信息。^{[47][48]}

BAAI UniVLA (2025)。另一篇同名工作以 Emu3 为基础，把视觉、语言和动作建模成统一离散 token，利用世界模型式视频后训练改善策略。它与上一项在作者、论文编号和机制上均不同：前者重点是任务潜动作，后者重点是统一多模态生成。其代码页面还展示增加推理步数的 CALVIN 结果，应核对预算后比较。^{[49][50]}

X-VLA (2025)。主视觉与语言使用 Florence-Large，辅助腕部视角单独编码，并用数据源/本体专用 soft prompts 与输入输出投影适配异构数据；标准 Transformer 以 flow matching 生成动作块。它将共享能力与硬件差异分开参数化，强调结构简洁和适配效率；soft prompt 的存在不意味着对未建模硬件免配置使用。^{[51][52]}

LingBot-VLA 2.0 (2026)。以 Qwen3-VL 系列主干、稀疏 MoE 动作专家及未来语义/深度蒸馏增强控制，数据约 6 万小时，含 20 种配置的 5 万小时机器人数据和 1 万小时人类第一视角数据。其 55 维规范动作/状态包含四个保留维，扩展至头、腰、底盘和灵巧手。报告中的 GM-100 混合训练表实际覆盖 9 个任务，两项长程测试每设置 15 次；结果展示了进展，但不能宣称已解决完整 GM-100 或普遍 OOD 操作。^{[53][54]}

模型关系与真正可比较的结论

必须区分五种边：架构或检查点继承、数据复用、辅助目标/模块引入、训练方式变化、系统组合。

OpenVLA→OFT 是明确适配；OXE→Octo/OpenVLA 是数据关系； $\pi 0.6$ →RECAP 是强化后训练；MEM→ $\pi 0.7$ 是模块继承；ER 2 与 Robotics 2 是互补系统。 $\pi 0$ 、GR00T、SmolVLA 的共同设计并不能证明它们互相继承权重。结构化关系文件对每条边分别标记明确证据或分析判断。^{[11][13][15][25][26][31][42]}

推理性能至少应分别报告 每次策略调用延迟、每次生成的动作数、实际观测更新频率、底层伺服频率、成功完成任务的吞吐率。RTC 在执行旧动作期间生成新动作，并固定已承诺的动作前缀来改善衔接；这是执行调度与条件构造，不是增加模型知识。更长动作块可能提高“动作生成吞吐”，同时让机器人更晚看到新变化，因此吞吐提速不能直接当反应速度提速。^[55]

横向实验应固定任务/机器人/场景拆分、数据量、预训练可见性、控制频率、动作空间、采样步数、重试预算及后训练方式，并同时报告成功率与置信区间。LIBERO 均分、CALVIN 链长、GM-100 进度分、长任务成功率和每小时完成数反映不同能力，不能混排为一个“通用具身智能榜单”。跨本体“零样本”还要指明究竟是新物体、新场景、新技能、新本体，还是只缺该技能 - 本体组合的数据。^{[15][32][38][50][53]}

4. 表征、层级推理与世界模型：从理解场景到预测行动后果

这一技术群不能按一个“模型越大、机器人越强”的排行榜理解。表征模型回答“当前状态怎样编码”，层级模型回答“下一步做什么”，动作策略回答“执行怎样的控制”，世界模型回答“假如执行这些控制，之后会发生什么”。一个系统可能覆盖多个角色，但只有完成感知、决策、动作执行和反馈更新，才形成真实机器人闭环。以下将论文实验、官方产品说明与本文分析分开；所有版本核验截至 2026-09-11。

SayCan、PaLM-E、EmbodiedGPT：语言推理怎样接上机器人

SayCan (2022) 解决语言计划缺乏可执行性的问题。输入是用户指令、已经选择的技能，以及当前状态下各技能的可供性评分；语言模型估计技能对任务的相关性，技能价值函数估计执行成功概率，两者共同决定下一技能。训练负担主要在已有技能策略和价值函数，推理时执行技能再选择下一步。它把语义常识与机器人能力分工连接起来，并没有把语言模型变成关节控制器。尤其应注意，原版 SayCan 对环境的反馈主要来自当前价值函数，不能因此声称已经完整解决失败检测与重规划；官方网站明确指出该限制。公开版本是桌面仿真实现，不等于完整移动操作栈开放。^[56]

PaLM-E (2023) 进一步把图像和连续状态编码成与文本同维的嵌入，插入解码器语言模型。用机器人规划、图文与语言任务联合训练，输出文本计划，再由底层策略执行；视觉反馈可以进入后续计划。它与 SayCan 的关键差别是将环境观测直接放进语言推理，不是简单换一个更大的文本模型。562B 版本体现的是多模态语义迁移，不代表 562B 网络以伺服频率输出电机命令。数据混合、感知落地和底层动作能力共同决定系统效果。^[57]

EmbodiedGPT (2023) 以 Ego4D 衍生的 EgoCOT 子目标数据适配7B语言模型，采用前缀调优，并从生成计划的查询中提取任务相关特征服务控制。其意义是学习“视觉 - 子目标 - 控制特征”的接口，而不仅仅把长指令展开成文字。Franka Kitchen和Meta-World中的改进应限于论文设置；文本推理质量与真实接触控制可靠性仍需分别验证。^[59]

VIMA 与 VoxPoser：任务接口和几何落地的两条路线

VIMA (2022预印本、ICML 2023) 将文字、目标物体图像、示范帧混合成一个任务提示。T5编码提示，带交叉注意力的因果Transformer读取提示和交互历史，逐步生成操作动作。600K+专家轨迹和四级泛化划分，使问题从“某个指令会不会做”转为“物体、组合、任务模板改变后是否仍会做”。这是一种以物体为中心的多模态条件策略；不能因为存在文字输入，就把它等同于继承互联网LLM能力的所有VLA。主要证据来自程序生成的桌面仿真任务，感知前端和真实动作分布迁移仍是额外问题。^[58]

VoxPoser (2023) 从另一方向解除固定技能库限制：语言模型生成程序，调用视觉语言组件构造三维可供性图、避障/姿态/速度等约束图，运动规划器在这些目标上寻找末端轨迹。视觉变化后重新计算地图并滚动规划，使高层语言输出不必每个控制周期重新生成。它把语言知识落在可检查的几何目标上，适合明确空间约束；代价是对分割、相机标定、可达性和动力学假设敏感。其“无需额外训练”指核心组件的组和使用，不意味着不需要预训练感知模型、控制器或真实系统集成。^[60]

R3M 与 VC-1：视觉编码器是基础设施，不是完整策略

R3M (2022) 利用Ego4D的人类视频，以时间对比、视频语言对齐和紧凑性约束训练视觉表征，冻结编码器后再学机器人控制。VC-1 (2023) 采用MAE式视觉预训练，并通过CortexBench跨导航、移动操作和灵巧操作等任务系统考察模型与数据规模；域适配能显著改变结论。两者共同说明互联网视觉经验可以降低下游数据需求，但不直接给出动作、长期规划或物理状态转移模型。^{[61][62]}

分析上，R3M/VC-1与VLA不是前后替代关系：它们可以成为策略的感知模块，也可作为检索、奖励或世界模型的编码器。评估编码器时须固定下游策略、演示数量、相机和微调协议；只比较编码器名字会把控制头和训练数据的作用混在一起。

PerAct → RVT，以及3D Diffuser Actor：几何归纳偏置与生成动作的结合

PerAct (2022) 将RGB-D重建为体素，结合语言，通过Perceiver处理三维patch，以分类方式选择下一末端位置体素及离散姿态/夹爪状态。核心思路是令观测与动作共享三维坐标系，使少量示范更容易约束六自由度操作。公开实验涵盖18项RLBench任务和少量真实机器人任务；体素分辨率、显存与标定误差构成明确代价。^[63]

RVT (2023) 针对密集三维表示的计算开销，把三维场景重新渲染成围绕工作空间的虚拟视角，用跨视图注意力融合，再预测夹爪位姿。它与PerAct在任务与三维动作目标上接近，主要改变三维信息的计算表达，因此是较清楚的效率改进关系；论文的训练与推理加速只适用于其硬件、实现和相同性能目标条件。^[64]

3D Diffuser Actor (2024) 把上述几何路线与扩散策略结合：语言和带深度的场景编码为三维token，将加噪的末端旋转/平移也表示成token，借助三维相对注意力逐步去噪。它解决的是多峰动作分布和视角泛化，预测对象是动作而非未来视频。RLBench中下一关键位姿还需底层运动规划器到达。官方实现特别记录了四元数wxyz/xyzw及不同RLBench协议的差异，说明坐标约定与评测环境本身会改变结果；不能把不一致协议下的成功率排成统一榜单。^{[65][66]}

DreamerV3：在潜空间学习后果，在想象中改进策略

DreamerV3 (2023预印本，2025 Nature论文) 是模型式强化学习算法，不是一个已在所有机器人上预训练好的通用控制权重。它从交互数据学习循环状态空间模型，以潜变量预测状态演化、奖励和终止；再在想象轨迹上优化actor-critic，实际行动后将新经验加入训练。归一化、目标变换和损失平衡用于提高跨任务稳定性。^{[67][68]}

它与视频世界模型的差异在于：控制优化发生在紧凑潜空间，训练时可以有图像重建，但不必在每次规划时生成可观看视频；与常规VLA的差异则是，策略改进依赖环境后果和奖励，而非仅拟合演示动作。统一超参数跨任务工作不等于一个权重跨任务零样本成功。探索成本、奖励设计和模型误差仍限制真实机器人的直接使用。

UniSim：视频生成器作为策略训练环境

UniSim (2023预印本、ICLR 2024) 用多来源图像、视频、导航与机器人数据训练条件视频生成器；条件既可以是高层语言行为，也可以是低层控制。推理时输入当前观测与行为，生成后续视觉经验，反复调用形成交互环境。论文用它生成经验来训练高层规划器和低层强化学习策略，并展示特定真实任务的迁移。^{[69][70]}

其贡献是将“生成视频”变成“按动作产生训练轨迹”的工具。本文分析认为，扩展到工程系统必须检查机器人动作是否真正改变预测分布、接触失败是否会被模型忠实呈现，以及策略是否利用了生成器漏洞。此处UniSim指Yang等的交互生成模型，不是同名的自动驾驶神经传感器仿真论文。

Genie 1 → 2 → 3：可交互环境逐代发展，物理控制结论仍需单独成立

Genie (2024) 由视频tokenizer、潜动作模型和动态预测器组成，从没有真实动作标签的视频中学习可控环境；潜动作是从帧变化推断的控制变量，不能直接视作真实机器人关节指令。Genie 2 (2024-12) 采用自回归潜空间扩散，以历史潜帧和用户动作生成下一帧，展示可交互三维环境。Genie 3 (2025-08) 官方展示720p、24fps和数分钟一致交互，并在2026年通过Project Genie原型提供部分用户体验。^{[71][72][73][74]}

这一系列推动的是环境生成、交互持续性和智能体训练载体。Genie 3公开说明直接动作空间有限，提示触发的世界事件未必由智能体自身执行，多主体交互也仍有困难。因此，能在生成场景中行走、改变天气或生成机器人视频，不构成机械臂精确接触、真实物体守恒、力矩闭环或长期安全性的验证。Genie 3完整训练语料与底层架构未在本章所核验的官方页面公开，不能把Genie 2的实现细节当作Genie 3已证实架构。

GR-1 与 GR-2：视频预训练怎样变成直接动作能力

GR-1 (2023) 先从大规模视频学习未来视觉变化，再以机器人轨迹适配；GPT式序列模型读取语言、图像历史和机器人状态，同时预测未来图像与动作。未来预测充当表征学习和时序监督，部署时仍可直接读取动作头，不必显式搜索所有未来。GR-2 (2024) 扩大到3800万视频片段、500亿以上token的预训练，再联合微调视频与动作预测。^{[75][76][77]}

这条线处在VLA与世界模型交界：比静态图文预训练多了动态经验，比纯模拟器多了可执行动作输出；但“同时预测画面和动作”并不自动说明推理时使用模型预测控制。GR-2的97.7%对应105项任务的Simple设置，未见操作设置明显更难，不能外推为开放家庭或未知机器人成功率。^[91]完整预训练语料与复现条件需单独审查。

V-JEPA 2 / 2-AC 与 V-JEPA 2.1：不重建像素的预测与规划

V-JEPA 2 (2025) 通过遮挡视频的潜特征预测训练编码器和预测器，避免把全部资源用于逐像素重建。V-JEPA 2-AC进一步使用不足62小时DROID机器人视频及动作记录训练动作条件动态预测器，以目标图像对应的特征作为规划目标，在真实Franka上滚动选择动作。所谓零样本是对部署环境/任务不再采集专门训练数据，不是从完全无动作数据的视频直接得到任意机器人控制。^{[78][79][81]}

V-JEPA 2.1 (2026-03) 对可见与遮挡token都施加密集预测损失，引入多层自监督与图像/视频tokenizer，并扩展模型和数据规模。机器人部分复用2-AC的预测器架构、公开代码和规划协议，替换视觉编码器后，在DROID上重新训练动作条件预测器；这不是直接继承已训练的2-AC预测器权重。论文Table 6中，同样约3秒规划预算下杯子抓取由60%到70%；80%的结果使用更长规划、约14秒。也就是说，常被概括的20个百分点提高同时包含了规划预算变化。每项技能只有10个测试任务，论文还指出夹爪时序会导致失败，因此不能声称已实现稳定实时通用操作。^{[80][81]}

分析上，JEPA路线选择“保留对任务有用的变化、忽略不必要像素细节”，视频生成路线选择“保留可观看的多模态未来”。两者并不互斥：潜空间规划可降低搜索成本，像素生成可用于人类审查和合成数据；关键是所保留的信息是否足以预测接触、遮挡和失败。

Cosmos Predict、Cosmos Policy 与 Cosmos 3：同一品牌内三种不同能力

Cosmos Predict 2.5是可接受文本、图像或视频的世界视频生成模型；Transfer 2.5侧重深度、边缘、分割等条件下的场景转换。它们首先是数据/环境生成组件，不应直接等同于机器人策略。^[82]

Cosmos Policy (2026-01) 则明确跨过动作边界：将Cosmos-Predict2-2B的视频潜帧槽复用于动作块、未来观测/本体状态和值，单阶段以目标平台示范后训练。同一个模型既能直接产生动作，也能采样多条候选行动，预测未来并按价值排序。论文分别报告直接策略和带规划设置，后者还可利用策略运行数据改进世界模型和值函数。工程上必须同时比较行动延迟、采样条数与成功率，不能把额外搜索带来的收益归给相同成本的直接策略。^{[83][90]}

Cosmos 3 (2026-05发布，核验至9月) 进一步以Mixture-of-Transformers组合自回归推理塔与扩散生成塔，支持视觉理解、世界预测及动作生成。当前官方仓库列出Super 64B、Nano 16B、Edge 4B，并列DROID后训练策略权重。Edge存在视频转换与分辨率限制；推荐端侧硬件并不表示所有模式都达到实时。核验的仓库当前许可证为OpenMDW-1.1，不能沿用旧Cosmos版本的许可证描述。完整预训练重现性、具体硬件延迟和陌生本体迁移需根据对应权重另测。^{[84][85]}

GAIA-2 → GAIA-3 → GAIA-4：自动驾驶世界模型的范围与启示

GAIA-2 (2025-03) 通过动作与结构化条件控制多摄像头未来生成；GAIA-3 (2025-12) 把重点推进到自动驾驶评估；GAIA-4 (2026-08) 官方展示让AI Driver的输出改变下一时刻模拟传感器输入，并联合生成相机与雷达数据。其world-on-rails模式令其他道路参与者沿真实日志轨迹运动，提供受控反事实比较；官方也说明可开启reactive agents，让选定参与者回应自车。^{[86][87][88]}

它们是驾驶领域的数据与验证基础设施，不能作为机械臂或人形机器人通用操作模型的直接证据。可迁移的方法论是：评估世界模型应同时评估生成保真度、闭环行为一致性和结果一致性。可观看的视频相似度只覆盖第一层，真实安全效果还受行为模型、传感器、场景覆盖和反事实假设限制。GAIA-4的详细网络与训练语料未在所核验官方页面充分公开，故保持“官方系统进展”证据等级。

模型之间的关系与架构选择

关系	技术解释	关系性质
SayCan → PaLM-E	从语言评分加可供性接口，转向直接读视觉/连续状态的语言规划	本文比较；不声称权重继承
R3M / VC-1 ↔ 动作策略	可复用感知表示，下游控制头仍要训练	模块互补
PerAct → RVT	保留三维动作落地，改变几何表示与计算路径	论文明确比较
几何策略 + 扩散策略 → 3D Diffuser Actor	三维相对注意力为动作去噪提供空间条件	论文明确方法融合
GR-1 → GR-2	视频预训练、联合视频动作建模向规模化延伸	系列与方法延伸
V-JEPA 2 → 2-AC；2.1编码器 + 2-AC框架	编码器系列扩展；复用预测器架构与规划协议并重新训练	分支扩展与框架复用，不等于权重继承
Cosmos Predict2 → Cosmos Policy	把预训练视频模型后训练成动作/未来/价值联合模型	明确初始化关系
Cosmos旧系列 → Cosmos 3	以推理与生成双塔统一多类能力	官方架构演进；不同同逐权重继承
Genie / UniSim / GAIA ↔ 策略	生成交互训练或评估环境，策略负责选择动作	系统分工
Dreamer ↔ VLA	前者通过动态与奖励学习改进策略，后者常从演示获得初始策略	本文提出的互补组合

本文建议先确定缺口，再决定是否需要世界模型：技能组合困难适合层级规划；空间精度不足优先改善几何与动作表示；示范少而有大量无动作视频，可考虑视频/潜表征预训练；任务需要比较多个行动后果，才值得承担规划的额外计算。MoLe-VLA是动态层跳过的VLA效率技术，而非世界模型，名称相似不能作为归类依据。^[89] 在需要人类协作、遮挡记忆、触觉和长期任务的场景，上述单一视觉路线都需要额外状态估计与反馈机制。

5. 全身控制与导航：把模型输出变成可持续执行的动作

具身模型至少跨越三个不同问题：决定目标、生成可执行的短期动作、在接触和扰动下保持稳定。一个能说出“把碗放进洗碗机”的模型，并不因此具备站立、避障或抓握控制。评估模型之间的关系，应先标明它处于哪一层，再讨论能否替换或组合；控制层的进步常与VLA互补。^{[99][102][110]}

从动作示范到运动先验

DeepMimic (2018) 将运动片段与任务奖励结合：身体状态、动作相位和目标进入策略，策略生成关节目标，通过物理反馈学习稳定执行。它的价值是将“模仿参考动作”和“完成目标”放进同一个优化问题。原论文主要展示物理仿真角色，包括机器人形态的仿真模型；这不是实际Atlas硬件部署证据。^[92]

AMP (2021) 与ASE (2022) 把重点从跟踪某个片段转向学习动作分布。AMP通过判别器给出动作风格奖励，减轻手工挑选和串联动作的负担；ASE进一步把可复用技能组织成潜变量，高层选择技能，低层执行。两者的关系是明确的方法扩展；与DeepMimic的关系在本报告中属于问题表述的演进，而非权重继承。局限是自然动作不等于正确完成任务，潜变量之间的切换也必须连续。^{[93][94]}

PHC (2023) 关注更难、也更接近长时间运行的问题：参考姿态带噪声或者角色摔倒后，能否恢复并继续？它以渐进式乘法控制策略扩展网络能力，把难动作和恢复技能纳入训练，避免把重置环境当作控制能力。其证据主要来自仿真avatar；从这里到真实执行器、传感器和人机接触，仍需要专门的sim-to-real工作。^{[95][96]}

Humanoid Transformer (2023) 走另一条路径：以观测 - 动作历史为上下文，自回归预测控制动作，在大规模随机化仿真中使用强化学习。运行时不更新权重，模型通过历史表现调整动作，对动力学不确定性形成隐式适应。这

里的“上下文学习”是运动执行中的适应，并不是看一段新任务视频便理解任务的同一种能力；实验范围也主要是行走、地形和扰动。^[97]

从人类动作到自主任务的数据闭环

H2O与OmniH2O (2024) 把人体运动重定向到机器人，利用具有额外信息的策略筛选不可行动作，再训练可部署的跟踪控制器。OmniH2O明确继承H2O，将运动学姿态变成统一接口：RGB、VR、语言生成的动作，或根据遥操作数据学出的策略，都可以提供目标姿态。特权教师使用的信息在部署时未必存在，因此需要蒸馏到稀疏输入的学生。把上层改成自主策略不意味着底层重新训练；这是其工程复用价值。遥操作实验必须与自主实验分开统计。^{[98][99]}

HumanPlus (2024) 把控制器进一步放进数据采集流程。先用40小时人类动作数据训练低层跟随能力，让人通过RGB摄像头“带着”人形机器人完成任务；再以真实采集的第一视角图像和动作进行行为克隆，获得视觉自主技能。它在定制33自由度机器人上展示了多种任务。核心贡献是把“人类动作先验→可用遥操作→机器人任务数据→视觉策略”闭合起来，不能将少量任务示范下的成功率解释为跨家庭通用成功率。^[100]

MaskedMimic (2024) 将多种控制接口统一成“缺失动作补全”：输入只给部分关节、路径、场景或文本约束，模型推断其余运动。训练先获得完整约束下的跟踪教师，再通过随机掩码和条件VAE学习部分约束策略。与直接回归唯一动作相比，这种表述承认同一目标可对应多种合理动作；主要证据仍是物理仿真角色，不能直接当作真机控制器。^[101]

SONIC：VLA与运动控制之间的明确接口

SONIC (2025预印本，2026期刊及工程更新) 把人类、机器人和混合姿态分别编码为共享量化运动token，再由统一控制解码器输出关关节目标，交给PD控制器执行。PPO运动跟踪、辅助重建和动力学随机化共同训练该接口。运行时还可由运动学规划器把操作者意图转换成短期参考运动，因此同一控制器能衔接VR、人体视频和VLA。^{[102][123]}

它尤其适合说明“上下层如何接起来”：原论文用300条遥操作轨迹微调GR00T N1.5，输出头部/腕部姿态、腰部高度及底座运动指令，再交给SONIC执行。论文明确将20次单任务试验定位为兼容性概念验证，不能扩展为通用机器人成功率。到核验时，官方仓库已经提供N1.7 workflow、训练代码、部署栈及SONIC v1.1；发布控制器为50 Hz。参考前视窗口、神经网络推理时间和整条遥操作链路延迟是三个不同量。^{[102][103]}

2026年的HoloMotion进一步探索参考动作条件下的MoE Transformer与训练部署流水线，本报告将其列为扩展阅读。它提示全身控制也在探索网络容量和数据规模，但不能仅凭“基础模型”命名推断已解决未知接触、任意地形或安全认证。^[124]

导航模型：局部策略、全局规划与空间记忆

ViNT (2023) 以视觉历史和目标图像为输入，用Transformer学习跨移动机器人可迁移的导航能力。输出局部路径点与目标距离估计，目标编码器可适配其他任务描述。长距离能力由局部模型、子目标生成、拓扑图及全局启发式协同形成；不是单个模型直接从像素输出所有电机指令。^{[104][105]}

NoMaD (2023预印本 / 2024会议) 明确复用ViNT编码器，以扩散动作解码器表达多条可能路线，并通过目标掩码统一探索与定向导航。它避免让模型对“左绕”和“右绕”简单求平均，但采样、路径选择、局部控制和下一帧反馈仍是执行系统的一部分。低碰撞率的实验结论不等于形式化无碰撞保证，更不等于人形机器人平衡控制能力。^[106]

GOAT (2023) 解决的是持续任务中的对象与空间记忆：将观测累积为实例级语义地图，根据类别、图像或语言找到特定对象，再导航；未知目标需要探索，已知目标可复用记忆。它是模块化系统，不是单一VLA，环境适应主要来自记忆更新。GOAT-Bench (2024) 则是多模态终身导航基准，必须与GOAT系统区分。局部导航策略、语义地图和VLA可以在架构上组合，但报告不把这种分析性互补写成已经实现的模型继承。^{[107][108]}

商业模型中的全身层次与上下文适应

Figure Helix→Helix 02是明确的版本扩展。原Helix主要处理上半身，Helix 02加入S0：S2形成语义目标，S1以200 Hz输出全身关节目标，S0以1 kHz执行平衡与接触相关控制。Figure披露S0使用超过1,000小时重定向人体运动和仿真强化学习；同时引入掌心视觉、指尖触觉。其四分钟房间任务是官方展示，不能替代多场景、带失败记录的可靠性测试；所谓单一系统仍具有明确多层次和多频率结构。^{[109][110]}

Skild Brain→S1把跨本体经验与任务适应放在同一产品路线中。S1使用演示条件下的分回合预训练，试图从一段任务视频推断意图、进度和自身动作，无需为每个新任务更新权重。公开文章没有披露完整网络、动作参数化或可复现训练配方，因此这些字段应标为未知，而不应凭“通用大脑”补写成某种Transformer或扩散结构。其公开扩展实验采用累积逐步评分，并允许失败后的人工恢复；不能将该分数等同于不中断的端到端自主任务完成率。^{[111][112]}

Generalist GEN-1→GEN-1.5提供一个重要对照：GEN-1强调选定任务经适配后的可靠性；GEN-1.5强调把感知-动作示范放进30秒上下文，以100 Hz产生动作轨迹。其官方报告称上下文能力从物理数据预训练中出现，并未专门设置上下文学习目标；Skild S1则明确描述演示条件训练。两者的输入、训练口径和测试任务不同，不能用单个成功率排行；Generalist也明确承认当前任务短、上下文策略比微调策略脆弱。^{[125][126]}

产品化证据与技术成熟度

产品进展分为可复现模型、开发平台、供应商演示、客户确认试点和持续商业运行，不能压缩成一个“已量产”标签。尤其应记录具体机器人、模型版本、是否需要现场或远程人工帮助，以及统计的分母。^{[114][117][118][128]}

机构	当前技术 / 产品形态	已核验进展	证据边界
Figure	Helix 02 / Figure 03	BMW确认此前Figure 02试点及Figure 03物流排序项目；Figure公开Helix 02现场示范	Figure 02历史产线数据不能归给Figure 03 / Helix 02。 ^{[127][128]}
Skild AI	跨本体Skild Brain / S1	官方报告已有付费客户、部署业务与新S1试点	商业汇总是企业自述，混合多个产品；“正在部署”“计划部署”“试点”各不相同。 ^[113]
Physical Intelligence	π模型作为合作方智能层	Weave洗衣房、Ultra仓储包装有合作方现场说明	部署案例使用的版本与π0.7研究模型不同；保留远程人工介入。 ^{[27][114]}
NVIDIA	GR00T模型、SONIC、仿真和机载部署生态	已提供模型 / 代码 / 训练部署 workflow；发布参考人形硬件	参考硬件公告写late 2026，不能算截止日已交付。 ^{[103][33][115]}
Google DeepMind	Gemini Robotics 2 / ER 2 / On-Device 2	2026年7月发布全身能力、多本体与本地执行路线	推理接口、受限测试接入和公开控制权重不是同一种开放程度。 ^[42]
Agility Robotics	Digit + Arc工业服务	GXO客户确认商业RaaS部署；供应商报告累计搬运里程碑	累计搬运数量缺少失败、人工介入与停机分母；不推定采用公开VLA。 ^{[118][119]}
1X	NEO / Redwood / 1XWM	家用机器人订购与2026交付计划；世界模型技术披露	页面明确基础自主能力和预约Expert Mode；订单不等于已交付自主机群。 ^{[116][117]}
Boston Dynamics	电动Atlas与学习行为栈	官方确认产品制造、工业试点经验及计划部署	硬件产品化不等于完整模型可复现或通用长期自主。 ^[120]
Unitree	G1平台 / UnifoLM-VLA	官方代码、模型权重与数据集入口	硬件销量、模型发布和自主商业效果分别核验。 ^[122]
Galbot	G1 / S1与AstraBrain	官方展示WAM、WBC与灵巧操作及行业应用路线	对“首个”“最大”“规模落地”保留供应商口径，不据此技术排名。 ^[121]
Generalist	GEN-1 / GEN-1.5	企业早期接入及真机适配 / 上下文学习试验	特定任务高可靠性与陌生任务one-shot能力属于不同条件。 ^{[125][126]}

关系图的阅读方式与工程推论

明确继承或复用包括AMP→ASE、H2O→OmniH2O、ViNT→NoMaD、Helix→Helix 02，以及已发布的GR00T - SONIC组合。PHC与SONIC、SONIC与Helix 02之间可以比较“把广泛运动先验放在上层目标之下”的共同思路，但没有证据说明二者共享权重或代码。关系文件分别标记explicit和analytical，避免把相似性误画成血缘关系。[\[94\]\[99\]\[102\]\[103\]\[106\]\[110\]](#)

工程上，接口至少要声明坐标系、控制频率、动作保持时长、命令过期策略和控制权限。语义层可以慢，平衡与接触层不能等待云端推理；人体参考动作也必须经过可达性与动力学约束检验。这是上述系统的比较推论，并非宣称所有产品采用相同实现。[\[98\]\[102\]\[110\]](#)

尚未闭合的关键问题集中在：陌生接触和负载下能否稳定执行；跨本体数据能否保留力学信息；多分钟任务能否自动发现失败并恢复；以及部署评测是否同时报告成功率、吞吐、人工时间和故障成本。运动片段更自然、视频更逼真或模型更大，都不能单独回答这些问题。[\[100\]\[102\]\[114\]\[116\]](#)

6. 补充模型拆解：数据、反馈与执行共同决定能力

GO-1：在语义与连续动作之间加入潜在计划

GO-1的输入包括多视角图像、任务指令和机器人状态。其VILLA框架由视觉语言骨干、潜动作规划器和扩散动作专家组成：先从人类视频等数据学习离散潜动作，再让规划器从当前观测预测潜动作序列，动作专家以这些中间表示为条件生成连续动作块。训练中的潜动作目标与最终机器人动作去噪目标不同。GO-1 Air移除潜规划器，是公开版本中直接观察“增加中间规划层是否值得”的对照入口。[\[132\]\[133\]](#)

其关系应理解为“视觉语义迁移 + 潜动作迁移 + 连续控制”的组合，而不是所有VLA的必然后继。潜动作可以吸收没有机器人控制标签的视频，但它仍需通过机器人数据对齐到具体可执行动作。数据规模与结构变化同时发生时，不能只把效果归因于规划器；同任务、同数据、同计算预算下比较完整GO-1与Air，更能检验中间计划的贡献。AgiBot World的大量采集机器人是硬件实例数量，不应改写为同等数量的不同本体。[\[132\]\[133\]](#)

SERL与HIL-SERL：从拟合演示走向利用纠错经验

SERL把视觉机器人强化学习中的训练、经验与机器人接口组合成可使用的软件系统，它不是一套可直接覆盖所有任务的预训练权重。HIL-SERL在此类样本高效强化学习路线中加入明确的人机反馈流程：先收集成功/失败状态训练奖励分类器，建立演示缓冲区，再在线执行策略、由人适时纠正，并将这些经验用于actor-critic学习。输入不仅有视觉和状态，还有稀疏成功信号与干预经验。[\[142\]\[143\]\[153\]](#)

与行为克隆相比，它的额外信息来自“偏离演示之后如何恢复”和“行动是否成功”。与通用VLA相比，它更接近对限定任务进行高精度后训练的方法。论文中的快速学习和高成功率不能脱离奖励标注、人工干预、重置和硬件配置计算成本。工程上应报告累计人工分钟、失败重置次数与每小时有效交互，而不是只计算梯度更新时间。[\[142\]\[153\]](#)

MolmoAct2：开放的具身推理骨干连接连续动作专家

MolmoAct2以Molmo2-ER具身推理视觉语言骨干为基础，加入机器人状态和流匹配连续动作专家，形成读取图像/语言/状态、输出动作块并闭环执行的系统。其公开资产覆盖训练阶段的基础检查点、若干机器人后训练策略和相关数据，适合分析“推理表征如何被动作头使用”。这不同于仅展示解释文字：动作模块仍需在机器人轨迹上学习适当的控制分布。[\[144\]\[145\]](#)

公开检查点进一步展示了训练路径：Molmo2-ER是起始视觉语言骨干；MolmoAct2-Pretrain是尚未接入连续动作专家的离散自回归VLA；最终MolmoAct2连接流匹配动作专家。MolmoAct2-Think则增加深度token推理，应作为独立变体标明，而不能把这一机制泛化到所有MolmoAct2部署策略。由此可分析两个不同问题：离散动作预训练怎样塑

造骨干，以及深度推理是否改善连续控制。二者的作用仍需固定机器人、数据与推理预算的消融；公开阶段权重本身不能证明收益归因。^{[144][145]}

其与GR00T、PI和小米的关系是模块形态上的接近：视觉语言理解与连续动作生成分工，但骨干、训练数据、对齐目标和部署协议各不相同，不能据此声称相互继承权重。开放的分阶段检查点提供消融机会；是否改善接触动作、陌生物体操作或长期恢复，仍需在固定评测条件下测量。基础检查点与经过具体本体微调的部署策略应分别选用。^[144]

Xiaomi-Robotics-0：把实时执行问题提前纳入训练

小米Robotics-0由Qwen3-VL-4B-Instruct和动作DiT组成，官方总参数量为4.7B。第一阶段通过Choice Policies等训练使VLM获得动作相关知识，并混合视觉语言数据；第二阶段冻结VLM，训练读取其KV与机器人状态的流匹配动作专家。后训练加入动作前缀约束与注意力/损失设计，使新的动作块衔接已承诺执行的动作，同时保持对视觉变化的响应。^[151]

部署实现输出30步动作块，异步执行时边运行当前动作边预测下一块，并丢弃推理期间已经过期的对应动作。公开说明强调异步模式需要相应训练的检查点，不能把任意同步权重接到异步队列就视为等价。它相对通用流匹配VLA的重要启发是：时延补偿不是最后附加的工程补丁，而会改变训练条件和分布。官方真实任务还使用了大量专项数据，因此应把强任务表现、少样本适配与零样本泛化分开讨论。^{[151][152]}

1XWM：从生成视频到动作的接口与限制

1XWM以文本和起始帧生成未来，再由逆动力学模型提取NEO的动作。2026年1月官方方案使用14B视频骨干，经第一视角人类视频和本体数据适配；逆动力学部分用Depth Anything特征和流匹配头从帧对预测控制。它说明视频先验仍需要独立的动作落地接口，不能把没有控制标签的视频直接当作机器人命令。^[116]

该版本生成5秒视频需约11秒多GPU推理，再花约1秒提取动作；长期闭环重规划被列为后续方向。因此，技术演示与即时反应、端侧运行或持续自主家务之间仍有明确差距。这里引用的是该次披露的方案与时延，不对截止日未披露的改进作推断。^[116]

7. 数据与评测：如何判断模型真的进步

数据资产的贡献与边界

数据或接口	核验的代表规模/特征	对模型的意义
Open X-Embodiment	原论文22种机器人，统一数据表示	验证跨本体共享；各模型实际混合子集不同 ^[9]
BridgeData V2	60,096条轨迹、24个环境；包含遥操作和脚本运行	物体与场景多样性；与OXE存在包含关系 ^[148]
DROID	76k条轨迹、350小时、564场景	分散真实环境采集；须注意标定与数据修订 ^[129]
RoboMIND	原论文107k条、479任务、96类物体	统一采集平台上的多本体数据 ^[131]
AgiBot World	Beta公布1,003,672条轨迹	双臂操作规模化；机器人实例数不等于本体种数 ^[132]
UMI / DexUMI	手持夹爪或人手接口，强调可迁移示范	降低采集约束，同时仍需时序、姿态与可达性对齐 ^{[130][147]}
RoboCasa365	365任务、2500+厨房；600+小时人工与1600+小时合成示范	系统化组合与场景覆盖；示范小时不能都算真机小时 ^{[149][154]}

这些规模不能相加得到“独立具身数据总量”：同一轨迹可被多个集合与训练混合重复使用；帧、步骤、片段、轨迹与小时是不同单位。人类视频擅长提供物体、任务与运动先验，却通常缺少执行器命令和触觉；真机轨迹具有动作落地价值，但覆盖成本高；仿真便于生成奖励与危险情形，仍受接触和传感器差距制约。数据价值应按覆盖的场景、本体、技能、失败恢复和传感模态分解。

LeRobot提供数据与机器人接口，Isaac Lab、ManiSkill等提供学习和仿真工具。这些基础设施使不同模型更易比较，但统一容器格式不等于统一控制语义。关节顺序、旋转约定、归一化、时间戳、相机标定和控制周期仍须逐项对齐。[\[138\]](#)[\[140\]](#)[\[141\]](#)

不同基准回答不同问题

基准	主要测量对象	比较前必须固定
LIBERO	语言操作、对象/空间/目标与迁移	套件、数据预处理、演示量、初始状态、rollout长度 [134]
CALVIN	连续语言子任务链	ABC-D等环境划分；平均完成链长不能当成功百分比 [135]
SIMPLER	特定真机设置的仿真代理评估	Visual Matching和Variant Aggregation、机器人与控制频率 [136]
RoboTwin 2.0	双臂操作、随机化与本体差异	clean/randomized设置、任务和动作接口 [137]
RMBench	依赖历史信息的操作	记忆任务划分、历史长度、检查点版本；2026有重训权重 [150]
RoboCasa365	厨房组合技能与环境泛化	版本、任务层级与时间限制；2026年5月任务horizon增加1.5倍 [149]
BEHAVIOR-1K	长程家庭活动与交互状态	具体挑战赛子集、观测限制、超时和本体；不是全1000任务统一已解决 [139] [155]
MolmoSpaces	多设置模型比较与场景扩展	数据来源、动作空间、覆盖任务、是否微调及测试日期 [146]

这解释了为什么本综述不提供一个“所有模型总排行榜”。高LIBERO成功率可能来自任务专项训练，较低的零样本跨场景分数反而测量更困难的问题；二者不能直接宣布优劣。模型更新还可能伴随更长horizon、更多采样或更高分辨率。至少应同时列出训练数据、是否见过任务/物体/场景/本体、模型版本、执行周期、推理预算和评测次数。

建议的统一验收设计

以下是研究与工程建议，不是本仓库已经执行的实验。建立四级测试：同分布技能；新物体/视角/语言；新场景与组合任务；新本体及长程自主运行。每级都包含扰动、遮挡、抓取失败和恢复情形，避免仅测试顺利路径。训练、验证、测试按场景和采集批次隔离，并报告预训练数据中的潜在重叠。

第一组基线固定动作接口与数据量，比较ACT/DP、可微调VLA和加入结构化规划的系统。第二组保持同一骨干，比较单步/动作块、离散/流生成、视觉/视觉加本体或触觉、同步/异步、记忆开/关。第三组对世界模型比较“无搜索、固定计算搜索、增加计算搜索”，分别报告模型能力与预算收益。对商业模型，无法控制训练数据时只做系统验收，不把差异解释成架构因果结论。

报告指标至少包含：任务成功和完整链成功；完成时间；人工干预每小时；恢复率；碰撞、掉落与急停；视觉到动作时延的中位数和尾部；单位任务能耗；数据采集与适配成本。每个任务与条件预先定义重复次数，并给出置信区间；按任务和场景分层统计，避免把同一场景的相关片段当成独立样本。全部尝试都进入日志，失败与超时不能剪辑消失。

8. 模型关系的综合论述


Learning paths across VLA and world models

The label on each connection states what is transferred or changed.


1. VLA adaptation and action-output recipe



2. VLM initialization, discrete pretraining, continuous actions



3. Action conditioning and an updated visual representation




Solid: specified method path. Blue: components combined for planning.

Dashed: encoder-series progression, not inheritance of action-predictor weights.

Training paths and framework reuse

Model relationships: lineage and composition

A family progression does not imply shared weights.



Solid: documented relationship. Blue: linked execution components.

Dashed: hierarchical-control analogy between Helix 02 and SONIC, not ancestry.

Model relationship map

关系不是单一谱系

本文将关系分为五类：明确初始化/复用、同系列版本演进、方法组合、系统互补、本文分析比较。只有原论文或官方实现明确说明时，才使用“继承权重”“在某模型上后训练”等表述。两个模型都使用Transformer或流匹配，仅能说明共享范式。附属关系数据记录每条边的证据来源与性质，读者可以检查图中箭头代表什么。

第一条关系是从专用模仿到通用条件策略。ACT与DP主要解决动作序列与多峰控制；RT系列、Octo与OpenVLA把任务与本体覆盖放到中心。后者并不让前者失效：数据较少、任务固定、算力受限时，紧凑行为克隆仍是有价值的基线；大VLA也经常采用动作块与生成头。在同等任务数据上比较，才能判断互联网预训练带来多少额外收益。

第二条关系是语言语义与动作分布的分工逐步显式化。RT-2将动作映射到语言式token空间，OpenVLA提供开放的迁移路线；PI、GR00T、MolmoAct2与小米等使用连续动作专家缓解细粒度控制与长动作序列的负担。FAST改变动作编码，OFT改变适配与动作输出配方，异步执行改变调度。这三个方向分别作用于表示、训练与运行时，不应简单排成前后代。

第三条关系是三维几何与大规模预训练互补。PerAct/RVT侧重让观测与动作共享空间结构，3D Diffuser Actor进一步结合生成动作。大VLM擅长语义迁移，但不会自动保证毫米级坐标、正确碰撞边界或接触状态。几何模块可以成为可检查接口，也可能增加标定与计算成本；是否融合应由空间误差来源决定。

第四条关系是世界模型与VLA正在靠近，但职责仍不同。GR-1/GR-2把未来预测纳入动作学习；GO-1用潜动作作中间计划；Cosmos Policy把视频基础模型适配为动作、未来和值的联合建模；JEPA-AC用潜空间行动后果支持搜索。它们提供四种不同连接方式：辅助监督、中间表示、统一生成、显式规划。只有当推理真的比较行动后果时，才应称其在部署时使用世界模型规划。^{[132][133][75][76][83][90][78][80][81]}

第五条关系是高层通用智能与低层全身控制的接口融合。HumanPlus、SONIC与Helix说明高层语义、动作目标和稳定执行可以工作在不同时间尺度。让VLA输出全身关节向量不等于已经解决平衡、接触与扰动恢复；让低层模型能稳定行走也不等于具备开放任务理解。接口必须携带目标坐标、时序、约束和失败反馈。

第六条关系是模仿、反馈后训练与在线学习逐渐形成循环。PI的经验学习方向与HIL-SERL分别展示通用预训练后优化和限定任务反馈优化的路径。两者共享利用实际结果改进策略的目标，但奖励、数据规模、可部署权重与安全边界不同，不能互换实验结论。世界模型可以降低真实探索成本，同时也会引入可被策略利用的模型偏差。

[142][143]

六组有助于选型的直接对照

对照	真正差异	应做的验证
ACT vs DP	潜变量动作块与去噪动作分布；模型/数据规模可独立改变	同演示量、同反馈周期的精度、失败率与时延
OpenVLA vs OFT	可复用骨干下的适配与动作输出配方变化	同骨干、同训练预算，而非只看名字
pi系列 vs GR00T系列	类似连续动作专家范式，不同骨干、混合数据、本体接口和版本目标	固定权重版本与数据许可，测本体适配成本
V-JEPA-AC vs 视频世界模型	紧凑潜空间后果预测 vs 可观看未来；都可能用于规划	同搜索时间、动作候选数和真实成功
语义规划器 + 技能 vs 端到端VLA	显式可检查子目标 vs 联合学习的动作接口	新组合、失败恢复、计划落地与模块开销
Helix/SONIC全身层级 vs 仅机械臂VLA	平衡与接触频率、全身动作接口和低层稳定性	行走中操作、扰动和多接触任务，而非静止桌面成绩

9. 工程架构与开放程度

建议将实际系统分为数据与标定、状态与历史、任务规划、动作生成、控制与安全边界、反馈记录六个接口。慢速语义推理可在服务器执行，动作专家在近端加速器运行，伺服与急停留在确定性控制路径。具体频率由硬件、任务和延迟测量决定，不根据营销中的System 1/System 2命名自行假定。生产闭环应知道当前动作基于哪一帧、哪个模型和哪个归一化版本。

开放程度至少分五项检查：论文机制、推理代码、权重、训练代码与配方、实际训练数据。再单列许可证与商业使用限制。一个模型有GitHub并不等于五项均完整；模型卡列出部署硬件也不等于所有模式都达到实时。公开数据和分阶段检查点有助复现，但标定、控制器与失败处理仍可能依赖团队经验。 [140][141][144]

工程选型宜从任务约束出发。固定、精细、演示可收集的工作站可先比较ACT/DP与HIL-SERL；需要语言泛化和多任务共享时比较开源VLA；存在明确空间约束时引入几何规划；需要选择不同后果时评估世界模型搜索；涉及行走与操作时先验证低层全身稳定性，再接入通用语义。这里是基于模型机制的选型建议，不是采购排名或部署保证。

10. 五个未来技术挑战

挑战一：可迁移的动作与接触表示

跨本体共享视觉和语言比共享执行器语义容易。不同关节、夹爪、手部、控制频率和力反馈使同一任务对应不同动作分布；人类视频还缺少真实控制标签。值得研究将本体约束、几何目标与接触状态显式编码，并在共享策略之下配置适配层。验收指标应包含新本体所需示范量、接触力误差、插接成功、约束违例和迁移后的稳定性，不能只测原本体成功率。

挑战二：长期记忆、可验证计划与失败恢复

真实任务需要记住被遮挡物体、已经完成的步骤和曾失败的策略。堆叠更多视频帧可能提高成本，也可能记住无关背景；文字计划可能与实际状态脱节。可研究事件级记忆、对象状态图、显式完成判据和带恢复分支的计划，将当前感知与长期状态区分。使用RMBench和长程基准作为部分测试入口，并增加真实遮挡、重新摆放与中断恢复；报告完整任务链成功率、恢复时间和错误记忆持续时间。^{[150][139]}

挑战三：可用于行动决策的世界模型

世界模型可能生成视觉上合理、控制上错误的未来，尤其在接触、可变形物体、遮挡和其他主体互动中。规划越长，误差越可能被策略放大；更大搜索预算也可能只是更有效地寻找模型漏洞。研究重点应包括行动条件校准、不确定性、物理约束和真实反馈校正。验收需要反事实动作辨别、预测与真实任务结果的一致性、固定预算的规划增益，以及异常情况下的保守退回行为。

挑战四：实时性、能耗与控制可靠性联合优化

大型视觉语言骨干、长历史与迭代动作生成争夺端侧计算资源；异步缓冲又改变反馈时效。值得将量化、蒸馏、KV复用、动作块调度和控制稳定性一起设计，并在扰动下测试动作衔接。验收指标应包含尾部时延、观测年龄、动作连续性、每任务能耗和故障恢复，而不是只测离线吞吐。小米异步训练案例说明训练条件与部署调度需要共同考虑。^{[151][152]}

挑战五：从演示成绩到可审计的持续学习

从成功视频筛选数据、只报告最佳checkpoint、隐藏人工接管，会高估实际能力。持续学习又会带来奖励错配、遗忘、数据泄漏和版本回退问题。研究与工程应保留所有尝试、干预和失败，建立独立场景测试与可回滚的模型发布过程；同时明确人类视频、场景资产、权重与训练数据的许可。验收应追踪跨版本回归、任务成功置信区间、人工分钟和长期干预频率，才能判断系统是否真正减少人类负担。^{[142][146][149]}

11. 阅读与复现路线

理解方法可依次阅读ACT/DP的动作学习，SayCan/PaLM-E的语义落地，RT/OpenVLA的预训练迁移，PI/GR00T的连续动作专家，PerAct/RVT的几何接口，再读JEPA/Cosmos与全身控制。复现实验宜从固定机械臂、清晰动作接口和少数可重复任务起步，随后增加域外变化与恢复情形；不要同时更换本体、传感器、数据和模型后再解释单个因素。

本仓库保留模型卡、关系边、数据与基准表、产品矩阵、证据与不确定性记录、双语报告以及构建与验证脚本。它提供研究资料和可执行的评测设计，不包含已经复现的模型训练结果，也不分发第三方论文全文、模型权重或原始机器人数据。后续更新应在同一来源台账中记录版本变化，并重新核对图、表和正文的一致性。

12. 模型与方法卡索引

下表统计模型、版本、方法和组件卡，不等于独立基础模型数量。完整逐字段拆解见 [Model Atlas](#)。

ID	Model / method	Year	Evidence
act	ACT	2023	^{[1][2]}
diffusion-policy	Diffusion Policy	2023	^{[3][4]}
rt1	RT-1	2022	^{[5][6]}
rt2	RT-2	2023	^{[7][8]}

ID	Model / method	Year	Evidence
rtx	RT-X / Open X-Embodiment	2023	[9][10]
octo	Octo	2024	[11][12]
openvla	OpenVLA	2024	[13][14]
openvla-oft	OpenVLA-OFT	2025	[15][16]
pi0	pi0	2024	[17][18][20]
fast	FAST / pi0-FAST	2025	[19][20]
pi05	pi0.5 / knowledge insulation	2025	[21][22][20]
pi06	pi0.6	2025	[23][24]
pi06-recap	pi-star-0.6 / RECAP	2025	[24][25]
mem	MEM / pi0.6-MEM	2026	[28]
pi07	pi0.7	2026	[26][27][20]
smolvla	SmoVLA	2025	[29][30]
groot-n1	GR00T N1	2025	[31]
groot-n15	GR00T N1.5	2025	[32][35]
groot-n16	GR00T N1.6	2025	[33][35]
groot-n17	GR00T N1.7	2026	[34][35]
gemini-robotics1	Gemini Robotics / ER	2025	[36][37]
gemini-robotics15	Gemini Robotics 1.5 / ER 1.5	2025	[38][39]
gemini-er16	Gemini Robotics-ER 1.6	2026	[40][41]
gemini-robotics2	Gemini Robotics 2	2026	[42]
gemini-er2	Gemini Robotics ER 2	2026	[42][43]
gemini-ondevice2	Gemini Robotics On-Device 2	2026	[42][44]
rdt1b	RDT-1B	2024	[45][46]
univla-odl	UniVLA (OpenDriveLab)	2025	[47][48]
univla-baai	UniVLA (BAAI)	2025	[49][50]
xvla	X-VLA	2025	[51][52]
lingbot-vla2	LingBot-VLA 2.0	2026	[53][54]
rtc	Real-Time Chunking (RTC)	2025	[55]
saycan	SayCan	2022	[56]
palme	PaLM-E	2023	[57]

ID	Model / method	Year	Evidence
embodiedgpt	EmbodiedGPT	2023	[59]
vima	VIMA	2023	[58]
voxposer	VoxPoser	2023	[60]
r3m	R3M	2022	[61]
vc1	VC-1	2023	[62]
peract	PerAct	2022	[63]
rvt	RVT	2023	[64]
3d-diffuser-actor	3D Diffuser Actor	2024	[65][66]
dreamerv3	DreamerV3	2023	[67][68]
unisim	UniSim	2023	[69][70]
genie1	Genie	2024	[71]
genie2	Genie 2	2024	[72]
genie3	Genie 3	2025	[73][74]
gr1	GR-1	2023	[75][76]
gr2	GR-2	2024	[77][91]
vjepa2	V-JEPA 2	2025	[78][79][81]
vjepa2-ac	V-JEPA 2-AC	2025	[78][79][81]
vjepa21	V-JEPA 2.1	2026	[80][81]
cosmos-predict25	Cosmos Predict 2.5	2025	[82]
cosmos-policy	Cosmos Policy	2026	[83][90]
cosmos3	Cosmos 3	2026	[84][85]
gaia2	GAIA-2	2025	[86]
gaia3	GAIA-3	2025	[87]
gaia4	GAIA-4	2026	[88]
cosmos-predict2	Cosmos Predict2-2B	2025	[83][90]
H-M01	DeepMimic	2018	[92]
H-M02	AMP / ASE	2021	[93][94]
H-M03	PHC	2023	[95][96]
H-M04	Humanoid Transformer	2023	[97]
H-M05	H2O / OmniH2O	2024	[98][99]

ID	Model / method	Year	Evidence
H-M06	HumanPlus	2024	[100]
H-M07	MaskedMimic	2024	[101]
H-M08	SONIC / GEAR-SONIC	2025	[102][103][123]
H-M09	ViNT	2023	[104][105]
H-M10	NoMaD	2023	[106][105]
H-M11	GOAT	2023	[107][108]
H-M12	Helix / Helix 02	2025	[109][110]
H-M13	Skild Brain / S1	2025	[111][112][113]
go1	GO-1 / GO-1 Air	2025	[132][133]
serl	SERL	2024	[143]
hil-serl	HIL-SERL	2024	[142][153]
molmoact2	MolmoAct2	2026	[144][145]
xiaomi-robotics-0	Xiaomi-Robotics-0	2026	[151][152]

13. 参考来源

以下按来源URL去重。日期为发布年份/日期或对应版本年份；动态页面按2026-09-11核验。别名、阅读范围和限制保存在sources.json。

- [1] Tony Z. Zhao et al.. [Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware](#). 2023-04-23.
- [2] Tony Z. Zhao et al.. [ALOHA / ACT project](#). n.d.; accessed 2026-09-11.
- [3] Cheng Chi et al.. [Diffusion Policy: Visuomotor Policy Learning via Action Diffusion](#). 2023-03-07.
- [4] Cheng Chi et al.. [Diffusion Policy \(IJRR manuscript\)](#). n.d.; accessed 2026-09-11.
- [5] Anthony Brohan et al.. [RT-1: Robotics Transformer for Real-World Control at Scale](#). 2022-12-13.
- [6] Robotics at Google. [RT-1 project](#). n.d.; accessed 2026-09-11.
- [7] Anthony Brohan et al.. [RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control](#). 2023-07-28.
- [8] Google DeepMind. [RT-2 project](#). n.d.; accessed 2026-09-11.
- [9] Open X-Embodiment Collaboration. [Open X-Embodiment: Robotic Learning Datasets and RT-X Models](#). 2023-10-13.
- [10] Google DeepMind and collaborators. [Open X-Embodiment repository](#). n.d.; accessed 2026-09-11.
- [11] Octo Model Team. [Octo: An Open-Source Generalist Robot Policy](#). 2024-05-20.
- [12] Octo Model Team. [Octo repository](#). n.d.; accessed 2026-09-11.
- [13] Moo Jin Kim et al.. [OpenVLA: An Open-Source Vision-Language-Action Model](#). 2024-06-13.
- [14] OpenVLA team. [OpenVLA repository](#). n.d.; accessed 2026-09-11.
- [15] Moo Jin Kim, Chelsea Finn, Percy Liang. [Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success](#). 2025-02-27.
- [16] Moo Jin Kim, Chelsea Finn, Percy Liang. [OpenVLA-OFT project](#). n.d.; accessed 2026-09-11.
- [17] Physical Intelligence. [pi0: A Vision-Language-Action Flow Model for General Robot Control](#). 2024-10-31.
- [18] Physical Intelligence. [pi0: Our First Generalist Policy](#). 2024-10-31.

- [19] Physical Intelligence. [FAST: Efficient Robot Action Tokenization](#). 2025-01-16.
- [20] Physical Intelligence. [openpi repository](#). n.d.; accessed 2026-09-11.
- [21] Physical Intelligence. [pi0.5: a Vision-Language-Action Model with Open-World Generalization](#). 2025-04-22.
- [22] Physical Intelligence. [VLAs that Train Fast, Run Fast, and Generalize Better](#). 2025-05-28.
- [23] Physical Intelligence. [pi0.6 Model Card](#). 2025-11-17.
- [24] Physical Intelligence. [pi-star-0.6: a VLA that Learns from Experience](#). 2025-11-17.
- [25] Physical Intelligence. [pi-star-0.6 / RECAP technical report](#). 2025-11-17.
- [26] Physical Intelligence. [pi0.7: a Steerable Model with Emergent Capabilities](#). 2026-04-16.
- [27] Physical Intelligence. [pi0.7: a Steerable Model with Emergent Capabilities](#). 2026-04-16.
- [28] Physical Intelligence. [VLAs with Long and Short-Term Memory](#). 2026-03-03.
- [29] Hugging Face and collaborators. [SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics](#). 2025-06-02.
- [30] Hugging Face. [SmolVLA: Efficient Vision-Language-Action Model trained on LeRobot Community Data](#). 2025-06-03.
- [31] NVIDIA GEAR Team. [GR00T N1: An Open Foundation Model for Generalist Humanoid Robots](#). 2025-03-18.
- [32] NVIDIA GEAR Team. [GR00T N1.5: An Improved Open Foundation Model](#). 2025-06-11.
- [33] NVIDIA GEAR Team. [GR00T N1.6: An Improved Open Foundation Model](#). 2025-12-15.
- [34] Edith Llonet and Brandon Neel / NVIDIA. [Develop Humanoid Robot Policies End-to-End with NVIDIA Isaac GR00T](#). 2026-07-07.
- [35] NVIDIA. [NVIDIA Isaac-GR00T repository](#). n.d.; accessed 2026-09-11.
- [36] Gemini Robotics Team. [Gemini Robotics: Bringing AI into the Physical World](#). 2025-03-25.
- [37] Google DeepMind. [Gemini Robotics brings AI into the physical world](#). 2025-03-12.
- [38] Gemini Robotics Team. [Gemini Robotics 1.5: Pushing the Frontier of Generalist Robots with Advanced Embodied Reasoning, Thinking, and Motion Transfer](#). 2025-10-02.
- [39] Google DeepMind. [Gemini Robotics 1.5 brings AI agents into the physical world](#). 2025-09-25.
- [40] Google DeepMind. [Gemini Robotics-ER 1.6 Model Card](#). 2026-04-20.
- [41] Laura Graesser and Peng Xu / Google DeepMind. [Gemini Robotics-ER 1.6: Powering real-world robotics tasks through enhanced embodied reasoning](#). 2026-04-14.
- [42] Carolina Parada / Google DeepMind. [Gemini Robotics 2 brings whole body intelligence to robots](#). 2026-07-30.
- [43] Google DeepMind. [Gemini Robotics ER 2 Model Card](#). 2026-07-30.
- [44] Google DeepMind. [Gemini Robotics On-Device 2 Model Card](#). 2026-07-30.
- [45] Songming Liu et al.. [RDT-1B: a Diffusion Foundation Model for Bimanual Manipulation](#). 2024-10-10.
- [46] Tsinghua RDT team. [RoboticsDiffusionTransformer repository](#). n.d.; accessed 2026-09-11.
- [47] Qingwen Bu et al.. [UniVLA: Learning to Act Anywhere with Task-centric Latent Actions](#). 2025-05-09.
- [48] OpenDriveLab. [UniVLA repository \(OpenDriveLab\)](#). n.d.; accessed 2026-09-11.
- [49] Yuqi Wang et al.. [Unified Vision-Language-Action Model](#). 2025-06-24.
- [50] BAAI Vision. [UniVLA repository \(BAAI\)](#). n.d.; accessed 2026-09-11.
- [51] Jinliang Zheng et al.. [X-VLA: Soft-Prompted Transformer as Scalable Cross-Embodiment Vision-Language-Action Model](#). 2025-10-11.
- [52] Tsinghua AIR / Shanghai AI Laboratory and collaborators. [X-VLA project](#). n.d.; accessed 2026-09-11.
- [53] Wei Wu et al.. [From Foundation to Application: Improving VLA Models in Practice](#). 2026-07-07.
- [54] Robbyant. [LingBot-VLA 2.0 repository](#). n.d.; accessed 2026-09-11.
- [55] Kevin Black, Manuel Y. Galliker, Sergey Levine. [Real-Time Execution of Action Chunking Flow Policies](#). 2025-06-09.
- [56] Michael Ahn et al.; Google Robotics / Everyday Robots. [Do As I Can, Not As I Say: Grounding Language in Robotic Affordances](#). 2022-04-04.
- [57] Danny Driess et al.; Google / TU Berlin. [PaLM-E: An Embodied Multimodal Language Model](#). 2023.
- [58] Yunfan Jiang et al.; Stanford / NVIDIA and collaborators. [VIMA: General Robot Manipulation with Multimodal Prompts](#). 2023.
- [59] Yao Mu et al.. [EmbodiedGPT: Vision-Language Pre-Training via Embodied Chain of Thought](#). 2023-05-24.

- [60] Wenlong Huang et al.; Stanford / UIUC. [VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models](#). 2023.
- [61] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, Abhinav Gupta. [R3M: A Universal Visual Representation for Robot Manipulation](#). 2022-03-23.
- [62] Arjun Majumdar et al.; Meta and collaborators. [Where are we in the search for an Artificial Visual Cortex for Embodied Intelligence?](#). 2023.
- [63] Mohit Shridhar, Lucas Manuelli, Dieter Fox. [Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation](#). 2022.
- [64] Ankit Goyal et al.; NVIDIA. [RVT: Robotic View Transformer for 3D Object Manipulation](#). 2023-06-26.
- [65] Tsung-Wei Ke, Nikolaos Gkanatsios, Katerina Fragkiadaki. [3D Diffuser Actor: Policy Diffusion with 3D Scene Representations](#). 2024.
- [66] Tsung-Wei Ke, Nikolaos Gkanatsios and collaborators. [3D Diffuser Actor official implementation](#). undated; accessed 2026-09-11.
- [67] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, Timothy Lillicrap. [Mastering Diverse Domains through World Models](#). 2023-01-10; revised 2024-04-17.
- [68] Danijar Hafner et al.. [Mastering diverse control tasks through world models](#). 2025.
- [69] Sherry Yang et al.; UC Berkeley / Google DeepMind / MIT. [UniSim: Learning Interactive Real-World Simulators](#). 2023; ICLR 2024.
- [70] Sherry Yang et al.. [Learning Interactive Real-World Simulators](#). 2023.
- [71] Jake Bruce et al.; Google DeepMind. [Genie: Generative Interactive Environments](#). 2024-02-23.
- [72] Google DeepMind. [Genie 2: A large-scale foundation world model](#). 2024-12-04.
- [73] Jack Parker-Holder and Shlomi Fruchter; Google DeepMind. [Genie 3: A new frontier for world models](#). 2025-08-05.
- [74] Google. [Project Genie: Experiment with infinite, interactive worlds](#). 2026.
- [75] Hongtao Wu et al.. [Unleashing Large-Scale Video Generative Pre-training for Visual Robot Manipulation](#). 2023-12-20.
- [76] Hongtao Wu et al.. [GR-1 project: Unleashing Large-Scale Video Generative Pre-training for Visual Robot Manipulation](#). 2023.
- [77] Chi-Lam Cheang et al.. [GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation](#). 2024-10-08.
- [78] Mahmoud Assran et al.; Meta FAIR. [V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning](#). 2025-06.
- [79] Meta FAIR. [Introducing V-JEPA 2](#). 2025.
- [80] Lorenzo Mur-Labadia et al.; Meta FAIR. [V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning](#). 2026-03-15.
- [81] Meta FAIR. [V-JEPA 2, 2-AC and 2.1 official code and checkpoints](#). updated 2026; accessed 2026-09-11.
- [82] NVIDIA. [Supported Models: NVIDIA NIM for Cosmos WFM](#). undated; accessed 2026-09-11.
- [83] Moo Jin Kim et al.; NVIDIA / Stanford. [Cosmos Policy: Fine-Tuning Video Models for Visuomotor Control and Planning](#). 2026-01-22.
- [84] Asawaree Bhide and Alexander Schwarz; NVIDIA. [Develop Physical AI Reasoning, World, and Action Models with NVIDIA Cosmos 3](#). 2026-05-31.
- [85] NVIDIA. [NVIDIA Cosmos official repository](#). current repository; accessed 2026-09-11.
- [86] Wayve research team. [GAIA-2: A Controllable Multi-View Generative World Model for Autonomous Driving](#). 2025-03-26.
- [87] Wayve. [Wayve launches GAIA-3, advancing world models from simulation to evaluation](#). 2025-12-02.
- [88] Wayve. [GAIA-4: Multimodal World Models Powering Closed-Loop Simulation for Safe and Scalable Autonomy](#). 2026-08-03.
- [89] Rongyu Zhang et al.. [MoLe-VLA: Dynamic Layer-skipping Vision Language Action Model via Mixture-of-Layers for Efficient Robot Manipulation](#). 2025-03-26.
- [90] NVIDIA / Stanford contributors. [Cosmos Policy official implementation](#). current repository; accessed 2026-09-11.
- [91] Chi-Lam Cheang et al.. [GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation \(full text\)](#). 2024-10-08.
- [92] Peng, Abbeel, Levine, van de Panne. [DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills](#). 2018.
- [93] Peng, Ma, Abbeel, Levine, Kanazawa. [AMP: Adversarial Motion Priors for Stylized Physics-Based Character Control](#). 2021.
- [94] Peng, Guo, Halper, Levine, Fidler. [ASE: Large-Scale Reusable Adversarial Skill Embeddings for Physically Simulated Characters](#). 2022.

- [95] Luo, Cao, Winkler, Kitani, Xu. [Perpetual Humanoid Control for Real-time Simulated Avatars](#). 2023-05-10.
- [96] Zhengyi Luo et al.. [PHC official implementation](#). 2023.
- [97] Radosavovic, Xiao, Zhang, Darrell, Malik, Sreenath. [Learning Humanoid Locomotion with Transformers](#). 2023.
- [98] He, Luo, Xiao, Zhang, Kitani, Liu, Shi. [Learning Human-to-Humanoid Real-Time Whole-Body Teleoperation](#). 2024-03-07.
- [99] He, Luo, He, Xiao, Zhang, Zhang, Kitani, Liu, Shi. [OmniH2O: Universal and Dexterous Human-to-Humanoid Whole-Body Teleoperation and Learning](#). 2024.
- [100] Fu, Zhao, Wu, Wetzstein, Finn. [HumanPlus: Humanoid Shadowing and Imitation from Humans](#). 2024.
- [101] Tessler, Guo, Nabati, Chechik, Peng. [MaskedMimic: Unified Physics-Based Character Control Through Masked Motion Inpainting](#). 2024-09-22.
- [102] Luo et al., NVIDIA. [SONIC: Supersizing Motion Tracking for Natural Humanoid Whole-Body Control](#). 2025-11-11.
- [103] NVIDIA. [GR00T-WholeBodyControl: SONIC and decoupled WBC](#). 2026-08-31.
- [104] Shah, Sridhar, Dashora, Stachowicz, Black, Hirose, Levine. [ViNT: A Foundation Model for Visual Navigation](#). 2023-06-26.
- [105] Berkeley AI Research. [General Navigation Models: GNM, ViNT and NoMaD](#). 2023.
- [106] Sridhar, Shah, Glossop, Levine. [NoMaD: Goal Masking Diffusion Policies for Navigation and Exploration](#). 2023.
- [107] Chang et al.. [GOAT: GO to Any Thing](#). 2023-11-10.
- [108] Khanna et al.. [GOAT-Bench: A Benchmark for Multi-Modal Lifelong Navigation](#). 2024-04-09.
- [109] Figure. [Helix: A Vision-Language-Action Model for Generalist Humanoid Control](#). 2025-02-20.
- [110] Figure. [Introducing Helix 02: Full-Body Autonomy](#). 2026-01-27.
- [111] Skild AI. [The case for an omni-bodied robot brain](#). 2025-09-24.
- [112] Skild AI. [Introducing S1: In-Context Learning for Robotics](#). 2026-08-18.
- [113] Deepak Pathak and Abhinav Gupta, Skild AI. [The Hidden Pillar of Robotics](#). 2026-09-09.
- [114] Physical Intelligence, Weave Robotics and Ultra. [The Physical Intelligence Layer](#). 2026-02-24.
- [115] NVIDIA. [NVIDIA Announces NVIDIA Isaac GR00T Reference Humanoid Robot for Academic Research](#). 2026-05-31.
- [116] 1X AI Team. [1X World Model: From Video to Action, A New Way Robots Learn](#). 2026-01-12.
- [117] 1X. [Order NEO](#). undated, accessed 2026-09-11.
- [118] GXO Logistics. [GXO Signs Industry-First Multi-Year Agreement with Agility Robotics](#). 2024-06-27.
- [119] Agility Robotics. [Digit Moves Over 100,000 Totes in Commercial Deployment](#). undated, accessed 2026-09-11.
- [120] Boston Dynamics. [Atlas Evolution From Research Robot to Industrial Humanoid](#). 2026, exact publication date unavailable.
- [121] Galbot. [Galbot company and technology overview](#). undated, accessed 2026-09-11.
- [122] Unitree Robotics. [UnifoLM-VLA official code and model release](#). 2026.
- [123] NVIDIA DAIR. [SONIC: Supersizing Motion Tracking for Natural Humanoid Whole-Body Control](#). 2026-07.
- [124] Horizon Robotics. [HoloMotion: A Foundation Model for Whole-Body Humanoid Control](#). 2026.
- [125] Generalist. [GEN-1: Scaling Embodied Foundation Models to Mastery](#). 2026-04-02.
- [126] Generalist. [GEN-1.5: Embodied Foundation Models are One-Shot Learners](#). 2026-08-19.
- [127] Figure. [F.03 Arrives at BMW](#). 2026-06-30.
- [128] BMW Group. [BMW Group advances the use of Physical AI in production with Figure 03 project in Spartanburg](#). 2026-06-25.
- [129] DROID Dataset Team. [DROID: A Large-Scale In-the-Wild Robot Manipulation Dataset](#). 2024.
- [130] Cheng Chi et al.. [Universal Manipulation Interface](#). 2024.
- [131] RoboMIND authors. [RoboMIND: Benchmark on Multi-embodiment Intelligence Normative Data for Robot Manipulation](#). 2024.
- [132] OpenDriveLab and AgiBot. [AgiBot World Colosseo repository](#). 2025.
- [133] AgiBot World Team. [AgiBot World Colosseo: Large-scale Manipulation Platform](#). 2025.
- [134] Bo Liu et al.. [LIBERO: Benchmarking Knowledge Transfer in Lifelong Robot Learning](#). 2023.
- [135] Oier Mees et al.. [CALVIN: A Benchmark for Language-Conditioned Policy Learning](#). 2022.
- [136] SIMPLER authors. [SIMPLER: Evaluating Real-World Robot Manipulation Policies in Simulation](#). 2024.
- [137] RoboTwin authors. [RoboTwin 2.0](#). 2025.

- [138] Stone Tao et al.. [ManiSkill3: GPU Parallelized Robotics Simulation and Rendering](#). 2025.
- [139] Stanford BEHAVIOR team. [BEHAVIOR-1K and 2026 challenge](#). 2026.
- [140] Hugging Face LeRobot team. [LeRobot: End-to-End Robot Learning](#). 2026.
- [141] NVIDIA and Isaac Lab contributors. [Isaac Lab](#). 2026.
- [142] Jianlan Luo, Charles Xu, Jeffrey Wu, Sergey Levine. [Precise and Dexterous Robotic Manipulation via Human-in-the-Loop Reinforcement Learning](#). 2024.
- [143] SERL authors. [SERL: A Software Suite for Sample-Efficient Robotic Reinforcement Learning](#). 2024.
- [144] Ai2 and MolmoAct2 authors. [MolmoAct2: Action Reasoning Models for Real-world Deployment](#). 2026-05-05.
- [145] Haoquan Fang et al.. [MolmoAct2: Action Reasoning Models for Real-world Deployment](#). 2026.
- [146] Ai2. [MolmoSpaces Robotics Benchmark and Leaderboard](#). 2026.
- [147] DexUMI authors. [DexUMI: Using Human Hand as the Universal Manipulation Interface for Dexterous Manipulation](#). 2025.
- [148] Homer Walke et al.. [BridgeData V2: A Dataset for Robot Learning at Scale](#). 2023.
- [149] RoboCasa team. [RoboCasa365](#). 2026.
- [150] Tianxing Chen et al.. [RMBench: Memory-Dependent Robotic Manipulation Benchmark](#). 2026.
- [151] Xiaomi Robotics. [Xiaomi-Robotics-0](#). 2026-02-12.
- [152] Xiaomi Robotics. [Xiaomi-Robotics-0 training and deployment](#). 2026.
- [153] Hugging Face. [HIL-SERL Real Robot Training Workflow Guide](#). 2026.
- [154] RoboCasa365 authors. [RoboCasa365: A Large-Scale Simulation Framework for Training and Benchmarking Generalist Robots](#). 2026.
- [155] Stanford BEHAVIOR team. [BEHAVIOR 2026 challenge evaluation](#). 2026.